001、试列出至少三种目前流行的大型数据库的名称:_____、_____、_____,其中您最熟悉的是_____,从_____年开始使用。

Oracle，Mysql，SQLServer Oracle 根据自己情况

002、有表 List，并有字段 A、B、C，类型都是整数。表中有如下几条记录：

A B C
2 7 9
5 6 4
3 11 9
现在对该表一次完成以下操作：
查询出 B 和 C 列的值，要求按 B 列升序排列
写出一条新的记录，值为{7,9,8}
查询 C 列，要求消除重复的值，按降序排列
写出完成完成以上操作的标准的 SQL 语句，并且写出操作 3 的结果。

```
create table List(A int,B int,C int)
Select B,C from List order by B
Insert into List values(7,9,8)
Select distinct(C) from List order by desc;
```

984

003、请简要说明视图的作用？

1.数据库视图隐藏了数据的复杂性。
2.数据库视图有利于控制用户对表中某些列的访问。
3.数据库视图使用户查询变得简单。

004、列举您使用过的 python 网络爬虫所用到的网络数据包（最熟悉的在前）：

requests、urllib、urllib2、httplib2
1. 请求
requests（第三方模块）
2. 解析：
bs4（即 beautifulsoup，第三方模块）
3. 储存：
pymongo（第三方模块）：
把数据写入 MongoDB
MySQL-python（第三方模块）：
把数据写入 MySQL 里面。
协程：gevent（第三方模块）

二、Python 数据分析&科学计算

numpy（第三方模块，C 拓展）：

Copy 了 MATLAB 的数据结构。很多数据分析和科学计算库的底层模块。提供了良好的数组数据结构和 C 拓展接口。

pandas（第三方模块，C 拓展）：

Copy 了 R 的 data frame 的数据结构。

005、列举您使用过的 python 网络爬虫所用到的解析数据包（最熟悉的在前）：

BeautifulSoup、pyquery、Xpath、lxml

006、列举您使用过的 python 中的编码方式（最熟悉的在前）：

UTF-8，ASCII，gbk

007、python3.5 语言中 enumerate 的意思是？

对于一个可迭代的（iterable）/可遍历的对象（如列表、字符串），enumerate 将其组成一个索引序列，利用它可以同时获得索引和值

enumerate 多用于在 for 循环中得到计数

008、99 的八进制表示是：143

009、请举出三种常用的排序算法？

冒泡、选择、快速

010、列出比较熟悉的爬虫框架？

Scrapy

011、用 4、9、2、7 四个数字，可以使用+、-、* 和 /，每个数字使用一次，使表达式的结果为 24？

表达式是（9+7-4）* 2

012、您最熟悉的 Unix 环境是？Unix 下查询环境变量的命令是？查询脚本定时任务的命令是？

1AIX，env，crontab

013、写出在网络爬虫爬取数据的过程中，遇到的防爬虫问题的解决方案

通过 headers 反爬虫：解决策略，伪造 headers

基于用户行为反爬虫：动态变化去爬取数据，模拟普通用户的行为

基于动态页面的反爬虫：跟踪服务器发送的 ajax 请求，模拟 ajax 请求

014、阅读以下 Python 程序？

```
for i in range(5,0,-1):
print(i)
```

请在下面写出打印结果：54321

015、简述 requests 模块的作用及基本使用？

```
# 作用：
使用 requests 可以模拟浏览器的请求
# 常用参数：
   url、headers、cookies、data、json、params、proxy
```

```
# 常用返回值：
    content
    iter_content
    text
    encoding="utf-8"
    cookie.get_dict()
```

016、简述 Beautifulsoup 模块的作用及基本使用？

```
#BeautifulSoup
用于从 HTML 或 XML 文件中提取、过滤想要的数据形式
#常用方法
解析：html.parser 或者 lxml（需要下载安装） 、find、find_all、text、attrs、get
https://www.cnblogs.com/wcwnina/p/8093987.html
```

018、Scrapy 框架中各组件的工作流程？

Scrapy 使用了 Twisted 异步非阻塞网络库来处理网络通讯，整体架构大致如下（绿线是数据流向）：

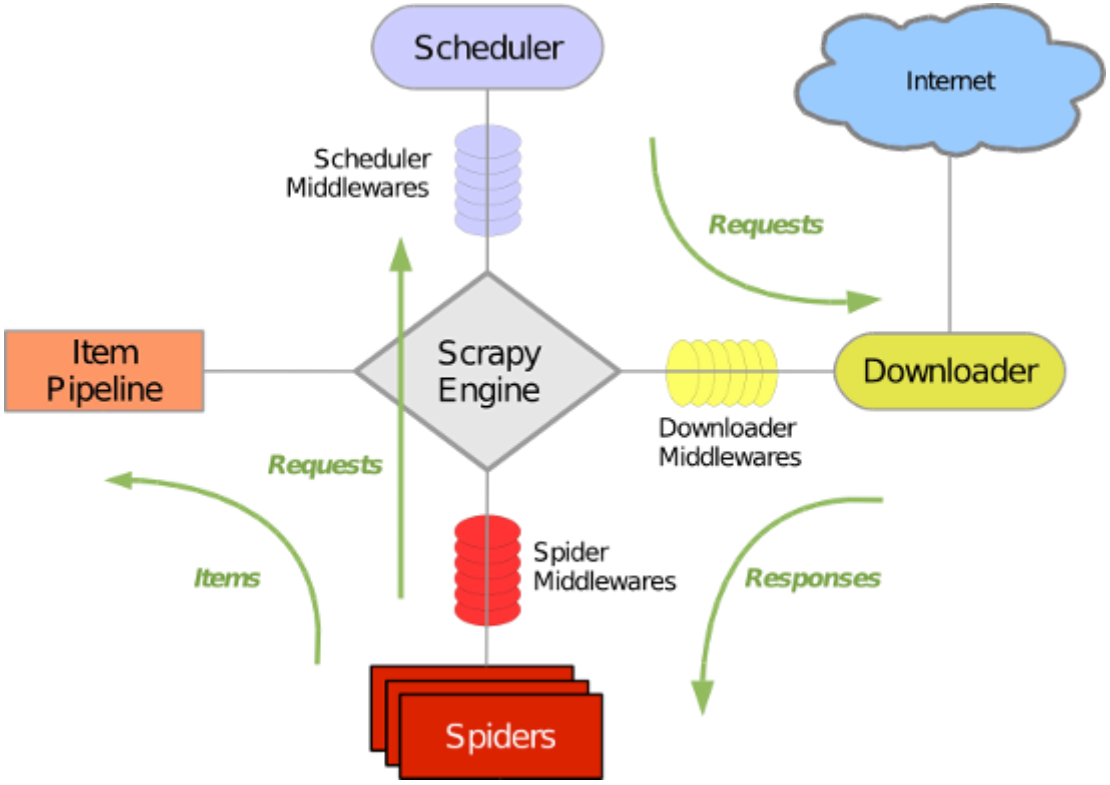

Scrapy 主要包括了以下组件：

- **引擎(Scrapy)**
- *用来处理整个系统的数据流处理, 触发事务(框架核心)*
- **调度器(Scheduler)**
- *用来接受引擎发过来的请求, 压入队列中, 并在引擎再次请求的时候返回. 可以想像成一个URL（抓取网页的网址或者说是链接）的优先队列, 由它来决定下一个要抓取的网址是什么, 同时去除重复的网址*
- **下载器(Downloader)**
- *用于下载网页内容, 并将网页内容返回给蜘蛛(Scrapy 下载器是建立在twisted 这个高效的异步模型上的)*
- **爬虫(Spiders)**
- *爬虫是主要干活的, 用于从特定的网页中提取自己需要的信息, 即所谓的实体(Item)。用户也可以从中提取出链接,让Scrapy 继续抓取下一个页面*
- **项目管道(Pipeline)**
- *负责处理爬虫从网页中抽取的实体，主要的功能是持久化实体、验证实体的有效性、清除不需要的信息。当页面被爬虫解析后，将被发送到项目管道，并经过几个特定的次序处理数据。*
- **下载器中间件(Downloader Middlewares)**
- *介于Scrapy 引擎和下载器之间的中间件，主要是处理Scrapy 引擎与下载器之间的请求及响应。*
- **爬虫中间件(Spider Middlewares)**
- *介于Scrapy 引擎和爬虫之间的中间件，主要工作是处理蜘蛛的响应输入和请求输出。*
- **调度中间件(Scheduler Middewares)**
- *介于Scrapy 引擎和调度之间的中间件，从 Scrapy 引擎发送到调度的请求和响应。*

Scrapy 运行流程大概如下：

```
1.引擎：Hi！Spider, 你要处理哪一个网站？
2.Spider：老大要我处理 xxxx.com（初始 URL）。
3.引擎：你把第一个需要处理的 URL 给我吧。
4.Spider：给你，第一个 URL 是 xxxxxxx.com。
5.引擎：Hi！调度器，我这有 request 请求你帮我排序入队一下。
6.调度器：好的，正在处理你等一下。
7.引擎：Hi！调度器，把你处理好的 request 请求给我。
8.调度器：给你，这是我处理好的 request
9.引擎：Hi！下载器，你按照老大的下载中间件的设置帮我下载一下这个 request 请求。
10.下载器：好的！给你，这是下载好的东西。（如果失败：sorry，这个 request 下载失败了。然后引擎告诉调度器，这个 request 下载失败了，你记录一下，我们待会儿再下载）
11.引擎：Hi！Spider，这是下载好的东西，并且已经按照老大的下载中间件处理过了，你自己处理一下（注意！这儿 responses 默认是交给 def parse()这个函数处理的）
```

12.Spider：（处理完毕数据之后对于需要跟进的 URL），Hi！引擎，我这里有两个结果，这个是我需要跟进的 URL，还有这个是我获取到的 Item 数据。
13.引擎：Hi ！管道 我这儿有个 item 你帮我处理一下！调度器！这是需要跟进 URL 你帮我处理下。然后从第四步开始循环，直到获取完老大需要全部信息。
14.管道、调度器：好的，现在就做！
https://blog.csdn.net/qq_37143745/article/details/80996707

030、项目发布的过程（上传-发布），上线，发布，测试，谁发布测试。

031、pandas 库有哪些函数，介绍 pandas 函数的作用：

前言：本博文摘抄自中国慕课大学上的课程《Python 数据分析与展示》，推荐刚入门的同学去学习，这是非常好的入门视频。

继续一个新的库，Pandas 库。Pandas 库围绕 Series 类型和 DataFrame 类型这两种数据结构，提供了一种高效便捷的数据处理方式。
一、常用功能及函数简介
包导入
一般我们需要做如下导入，numpy 和 pandas 一般需要联合使用：

```
import pandas as pd
import numpy as np
```

本文采用如下缩写：
df：Pandas DataFrame 对象
s： Pandas Series 对象
数据导入
pd.read_csv(filename)：从 CSV 文件导入数据
pd.read_table(filename)：从限定分隔符的文本文件导入数据
pd.read_excel(filename)：从 Excel 文件导入数据
pd.read_sql(query, connection_object)：从 SQL 表/库导入数据
pd.read_json(json_string)：从 JSON 格式的字符串导入数据
pd.read_html(url)：解析 URL、字符串或者 HTML 文件
pd.read_clipboard()：从粘贴板获取内容
pd.DataFrame(dict)：从字典对象导入数据
数据导出
df.to_csv(filename)：导出数据到 CSV 文件
df.to_excel(filename)：导出数据到 Excel 文件
df.to_sql(table_name, connection_object)：导出数据到 SQL 表
df.to_json(filename)：以 Json 格式导出数据到文本文件
创建对象
pd.DataFrame(np.random.rand(20,5))：创建 20 行 5 列的随机数组成的 DataFrame 对象

pd.Series(my_list)：从可迭代对象 my_list 创建一个 Series 对象
df.index = pd.date_range('1900/1/30', periods=df.shape[0])：增加一个日期索引
index 和 reindex 联合使用很有用处，index 可作为索引并且元素乱排序之后，所以跟着元素保持不变，因此，当重拍元素时，只需要对 index 进行才重排即可:reindex。
另外， reindex 时，还可以增加新的标为 NaN 的元素。
数据查看
df.head(n)：查看 DataFrame 对象的前 n 行
df.tail(n)：查看 DataFrame 对象的最后 n 行
df.shape()：查看行数和列数
df.info()：查看索引、数据类型和内存信息
df.describe()：查看数值型列的汇总统计
s.value_counts(dropna=False)：查看 Series 对象的唯一值和计数
df.apply(pd.Series.value_counts)：查看 DataFrame 对象中每一列的唯一值和计数
apply 的用处很多，比如可以通过跟 lambda 函数联合，完成很多功能：将包含某个部分的元素挑出来等等。
cities['Is wide and has saint name'] = (cities['Area square miles'] > 50) & cities['City name'].apply(lambda name: name.startswith('San'))
数据选取
df[col]：根据列名，并以 Series 的形式返回列
df[[col1, col2]]：以 DataFrame 形式返回多列
s.iloc[0]：按位置选取数据
s.loc['index_one']：按索引选取数据
df.iloc[0,:]：返回第一行
数据清洗
df.columns = ['a','b','c']：重命名列名
pd.isnull()：检查 DataFrame 对象中的空值，并返回一个 Boolean 数组
pd.notnull()：检查 DataFrame 对象中的非空值，并返回一个 Boolean 数组
df.dropna()：删除所有包含空值的行
df.fillna(x)：用 x 替换 DataFrame 对象中所有的空值
s.astype(float)：将 Series 中的数据类型更改为 float 类型
s.replace(1,'one')：用 ‘one’ 代替所有等于 1 的值
df.rename(columns=lambda x: x + 1)：批量更改列名
df.set_index('column_one')：更改索引列
数据处理：Filter, Sort, GroupBy
df[df[col] > 0.5]：选择 col 列的值大于 0.5 的行

df.sort_values(col1)：按照列 col1 排序数据，默认升序排列
df.groupby(col)：返回一个按列 col 进行分组的 Groupby 对象
df.groupby(col1).agg(np.mean)：返回按列 col1 分组的所有列的均值
df.pivot_table(index=col1, values=[col2,col3], aggfunc=max)：创建一个按列 col1 进行分组，并计算 col2 和 col3 的最大值的数据透视表
data.apply(np.mean)：对 DataFrame 中的每一列应用函数 np.mean
数据合并
df1.append(df2)：将 df2 中的行添加到 df1 的尾部
df.concat([df1, df2],axis=1)：将 df2 中的列添加到 df1 的尾部
df1.join(df2,on=col1,how='inner')：对 df1 的列和 df2 的列执行 SQL 形式的 join
数据统计
df.describe()：查看数据值列的汇总统计
df.mean()：返回所有列的均值
df.corr()：返回列与列之间的相关系数
df.count()：返回每一列中的非空值的个数
df.max()：返回每一列的最大值
df.min()：返回每一列的最小值
df.median()：返回每一列的中位数
df.std()：返回每一列的标准差
Pandas 支持的数据类型
int 整型
float 浮点型
bool 布尔类型
object 字符串类型
category 种类
datetime 时间类型
补充：
df.astypes: 数据格式转换
df.value_counts:相同数值的个数统计
df.hist(): 画直方图
df.get_dummies: one-hot 编码，将类型格式的属性转换成矩阵型的属性。比如：三种颜色 RGB，红色编码为[1 0 0]

160.列举您使用过的 Python 网络爬虫所用到的网络数据包?

requests, urllib,urllib2, httplib2

161.爬取数据后使用哪个数据库存储数据的，为什么？

162、你用过的爬虫框架或者模块有哪些？谈谈他们的区别或者优缺点？

Python 自带：urllib，urllib2
第　三　方：requests
框　　架：Scrapy
urllib 和 urllib2 模块都做与请求 URL 相关的操作，但他们提供不同的功能。
urllib2.：urllib2.urlopen 可以接受一个 Request 对象或者 url，（在接受 Request 对象时候，并以此可以来设置一个 URL 的 headers），urllib.urlopen 只接收一个 url
urllib 有 urlencode,urllib2 没有，因此总是 urllib，urllib2 常会一起使用的原因
scrapy 是封装起来的框架，他包含了下载器，解析器，日志及异常处理，基于多线程， twisted 的方式处理，对于固定单个网站的爬取开发，有优势，但是对于多网站爬取 100 个网站，并发及分布式处理方面，不够灵活，不便调整与括展。
request 是一个 HTTP 库， 它只是用来，进行请求，对于 HTTP 请求，他是一个强大的库，下载，解析全部自己处理，灵活性更高，高并发与分布式部署也非常灵活，对于功能可以更好实现.
Scrapy 优缺点：
优点：scrapy 是异步的
采取可读性更强的 xpath 代替正则
强大的统计和 log 系统
同时在不同的 url 上爬行
支持 shell 方式，方便独立调试
写 middleware,方便写一些统一的过滤器
通过管道的方式存入数据库
缺点：基于 python 的爬虫框架，扩展性比较差
基于 twisted 框架，运行中的 exception 是不会干掉 reactor，并且异步框架出错后是不会停掉其他任务的，数据出错后难以察觉。

007、写爬虫是用多进程好？还是多线程好？为什么？

IO 密集型代码(文件处理、网络爬虫等)，多线程能够有效提升效率(单线程下有 IO 操作会进行 IO 等待，造成不必要的时间浪费，而开启多线程能在线程 A 等待时，自动切换到线程 B，可以不浪费 CPU 的资源，从而能提升程序执行效率)。在实际的数据采集过程中，既考虑网速和响应的问题，也需要考虑自身机器的硬件情况，来设置多进程或多线程

008、常见的反爬虫和应对方法？

1）.通过 Headers 反爬虫
从用户请求的 Headers 反爬虫是最常见的反爬虫策略。很多网站都会对 Headers 的 User-Agent 进行检测，还有一部分网站会对 Referer 进行检测（一些资源网站的防盗链就是检测 Referer）。如果遇到了这类反爬虫机制，可以直接在爬虫中添加 Headers，将浏览器的 User-Agent 复制到爬虫的 Headers 中；或者将 Referer 值修改为目标网站域名。对于检测 Headers 的反爬虫，在爬虫中修改或者添加 Headers 就能很好的绕过。
2）.基于用户行为反爬虫
还有一部分网站是通过检测用户行为，例如同一 IP 短时间内多次访问同一页面，或者同一账户短时间内多次进行相同操作。

大多数网站都是前一种情况，对于这种情况，使用 IP 代理就可以解决。可以专门写一个爬虫，爬取网上公开的代理 ip，检测后全部保存起来。这样的代理 ip 爬虫经常会用到，最好自己准备一个。有了大量代理 ip 后可以每请求几次更换一个 ip，这在 requests 或者 urllib2 中很容易做到，这样就能很容易的绕过第一种反爬虫。
对于第二种情况，可以在每次请求后随机间隔几秒再进行下一次请求。有些有逻辑漏洞的网站，可以通过请求几次，退出登录，重新登录，继续请求来绕过同一账号短时间内不能多次进行相同请求的限制。
3）.动态页面的反爬虫
上述的几种情况大多都是出现在静态页面，还有一部分网站，我们需要爬取的数据是通过 ajax 请求得到，或者通过 JavaScript 生成的。首先用 Fiddler 对网络请求进行分析。如果能够找到 ajax 请求，也能分析出具体的参数和响应的具体含义，我们就能采用上面的方法，直接利用 requests 或者 urllib2 模拟 ajax 请求，对响应的 json 进行分析得到需要的数据。
能够直接模拟 ajax 请求获取数据固然是极好的，但是有些网站把 ajax 请求的所有参数全部加密了。我们根本没办法构造自己所需要的数据的请求。这种情况下就用 selenium+phantomJS，调用浏览器内核，并利用 phantomJS 执行 js 来模拟人为操作以及触发页面中的 js 脚本。从填写表单到点击按钮再到滚动页面，全部都可以模拟，不考虑具体的请求和响应过程，只是完完整整的把人浏览页面获取数据的过程模拟一遍。
用这套框架几乎能绕过大多数的反爬虫，因为它不是在伪装成浏览器来获取数据（上述的通过添加 Headers 一定程度上就是为了伪装成浏览器），它本身就是浏览器，phantomJS 就是一个没有界面的浏览器，只是操控这个浏览器的不是人。利 selenium+phantomJS 能干很多事情，例如识别点触式（12306）或者滑动式的验证码，对页面表单进行暴力破解等。

165.解析网页的解析器使用最多的是哪几个?

166.需要登录的网页，如何解决同时限制 ip，cookie,session

010、爬虫过程中验证码怎么处理？

1.scrapy 自带（但是成功率不高）；2.付费接口（若快 http://www.ruokuai.com/home/pricetype）

168.使用最多的数据库，对他们的理解？

169.编写过哪些爬虫中间件？

170.“极验”滑动验证码如何破解？

171.爬虫多久爬一次，爬下来的数据是怎么存储？

172.cookie 过期的处理问题？

173.动态加载又对及时性要求很高怎么处理？

174.HTTPS 有什么优点和缺点？

175.HTTPS 是如何实现安全传输数据的？

176.TTL，MSL，RTT 各是什么？

177.谈一谈你对 Selenium 和 PhantomJS 了解

178.平常怎么使用代理的 ？

179.存放在数据库(redis、mysql 等)。

180.怎么监控爬虫的状态?

181.描述下 scrapy 框架运行的机制？

答：从 start_urls 里获取第一批 url 并发送请求，请求由引擎交给调度器入请求队列，获取完毕后，调度器将请求队列里的请求交给下载器去获取请求对应的响应资源，并将响应交给自己编写的解析方法做提取处理：1. 如果提取出需要的数据，则交给管道文件处理；2. 如果提取出 url，则继续执行之前的步骤（发送 url 请求，并由引擎将请求交给调度器入队列...），直到请求队列里没有请求，程序结束。

182.谈谈你对 Scrapy 的理解？

183.怎么样让 scrapy 框架发送一个 post 请求（具体写出来）

184.怎么监控爬虫的状态 ？

185.怎么判断网站是否更新？

186.图片、视频爬取怎么绕过防盗连接

187.你爬出来的数据量大概有多大？大概多长时间爬一次？

188.用什么数据库存爬下来的数据？部署是你做的吗？怎么部署？

189.增量爬取

190.爬取下来的数据如何去重，说一下 scrapy 的具体的算法依据。

191.Scrapy 的优缺点?

192.怎么设置爬取深度？

193.scrapy 和 scrapy-redis 有什么区别？

答：scrapy 是一个 Python 爬虫框架，爬取效率极高，具有高度定制性，但是不支持分布式。而 scrapy-redis 一套基于 redis 数据库、运行在 scrapy 框架之上的组件，可以让 scrapy 支持分布式策略，Slaver 端共享 Master 端 redis 数据库里的 item 队列、请求队列和请求指纹集合。

194.为什么选择 redis 数据库？

因为 redis 支持主从同步，而且数据都是缓存在内存中的，所以基于 redis 的分布式爬虫，对请求和数据的高频读取效率非常高。

194.分布式爬虫主要解决什么问题？

1）ip
2）带宽
3）cpu
4）io

195.什么是分布式存储？

196.你所知道的分布式爬虫方案有哪些？

197.scrapy-redis，有做过其他的分布式爬虫吗？

001、python 爬虫 scrapy 项目（一）

爬取目标：腾讯招聘网站（起始 url：https://hr.tencent.com/position.php?keywords=&tid=0&start）
爬取内容：职位；职位类型；招聘人数；工作地点；发布时间；招聘详细链接；工作职责；工作要求
反反爬措施：设置随机 user-agent、设置请求延时操作、

1、开始创建项目

```
scrapy startproject tencent
```

2、进入 **tencent** 文件夹，执行启动 **spider** 爬虫文件代码，编写爬虫文件。

```
scrapy genspider hr "tencent.com"
```

命令执行完，用 Python 最好的 IDE---pycharm 打开该文件目录，会在你的当前目录创建如下文件目录。

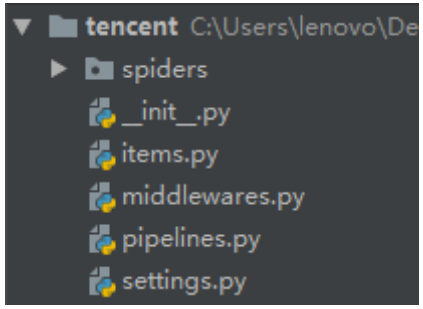

3、编写该目录下的 **items.py** 文件，设置你需要爬取的字段。

```
class TencentItem(scrapy.Item):
    # define the fields for your item here like:
        # 职位
        position = scrapy.Field()
        # 职位类型
        position_type = scrapy.Field()
        # 招聘人数
        persons = scrapy.Field()
        # 工作地点
        place = scrapy.Field()
        # 招聘发布时间
        time = scrapy.Field()
        # 职位详细链接
        detail_link = scrapy.Field()
        # 工作职责
```

```
        work_duty = scrapy.Field()
        # 工作要求
        work_request = scrapy.Field()
```

4、进入 spiders 文件夹，打开 hr.py 文件,开始编写爬虫文件

```
# -*- coding: utf-8 -*-
import scrapy
import re
from items import TencentItem

class HrSpider(scrapy.Spider):
    name = 'hr'
    allowed_domains = ['tencent.com']
    offset = 0
    original_url = 'https://hr.tencent.com/position.php?keywords=&tid=0&start='
    # 设置动态起始 url
    start_urls = ['https://hr.tencent.com/position.php?keywords=&tid=0&start=' + str(offset)]

    def parse(self, response):
        # 编写 xpath 规则提取需要的数据，进行数据清洗。
        trs = response.xpath("//table[@class='tablelist']//tr")[1:-1]
        for tr in trs:
            item = TencentItem()
            item["position"] = tr.xpath("./td[1]/a/text()").extract()
            item["position_type"] = tr.xpath("./td[2]/text()").extract()
            item["persons"] = tr.xpath("./td[3]/text()").extract()
            item["place"] = tr.xpath("./td[4]/text()").extract()
            item["time"] = tr.xpath("./td[5]/text()").extract()
            link_part = tr.xpath("./td[1]/a/@href").extract_first()
            # 分析网址结构，拼接正确的职位详细链接
            url_detail = item["detail_link"] = 'https://hr.tencent.com/' + link_part
            # 将找到的详细链接 yield 到 scrapy 的调度器，调度器进行入队列，依次发送请求。
            yield scrapy.Request(url=url_detail,
                                 callback=self.parse_next_url,#编写处理链接的回调函数
                                 meta = {"item":item},
```

```
                                        )
        # 进行翻页操作
        if self.offset < 2870:
            self.offset += 10
            url_send = self.original_url + str(self.offset)
            yield scrapy.Request(
                url=url_send,
                callback=self.parse,
                                    )
    # 编写回调函数
    def parse_next_url(self,response):
        item = response.meta["item"]
        item["work_duty"] = response.xpath("//table[@class='tablelist textl']//tr[3]//ul//text()").extract()
        item["work_request"] = response.xpath("//table[@class='tablelist textl']//tr[4]//ul//text()").extract()
        item["work_duty"] = re.sub(r'(\xa0)','',str(item["work_duty"]))
        item["work_request"] = re.sub(r'(\xa0)','',str(item["work_request"]))
        yield item
```

5、编写 pipeline.py 文件，处理接收到的数据

```
import json


class TencentPipeline(object):
    # 自定义一个打开文件，写入文件的方式存储数据
    def __init__(self):
        self.f = open("tencent.json","wb")

    def process_item(self, item, spider):
        # 当 item 文件中有中文时，ensure 默认是用 ascii 编码中文
        content = json.dumps(dict(item),ensure_ascii= False) + ", \n"
        self.f.write(content.encode("utf-8"))
        return item

    def close_file(self):
          self.f.close()
```

6、设置 setting.py 文件，配置 scrapy 运行的相关内容

```
DOWNLOADER_MIDDLEWARES = {
   'tencent.middlewares.RandomUA': 543,
}
ITEM_PIPELINES = {
   'tencent.pipelines.TencentPipeline': 300,
   #  'scrapy_redis.pipelines.RedisPipeline': 400,
}
USER_AGENT = [
    "Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/537.1 (KHTML, like Gecko) Chrome/22.0.1207.1 Safari/537.1",
    "Mozilla/5.0 (X11; CrOS i686 2268.111.0) AppleWebKit/536.11 (KHTML, like Gecko) Chrome/20.0.1132.57 Safari/536.11",
    "Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/536.6 (KHTML, like Gecko) Chrome/20.0.1092.0 Safari/536.6",
    "Mozilla/5.0 (Windows NT 6.2) AppleWebKit/536.6 (KHTML, like Gecko) Chrome/20.0.1090.0 Safari/536.6",
    "Mozilla/5.0 (Windows NT 6.2; WOW64) AppleWebKit/537.1 (KHTML, like Gecko) Chrome/19.77.34.5 Safari/537.1",
    "Mozilla/5.0 (X11; Linux x86_64) AppleWebKit/536.5 (KHTML, like Gecko) Chrome/19.0.1084.9 Safari/536.5",
    "Mozilla/5.0 (Windows NT 6.0) AppleWebKit/536.5 (KHTML, like Gecko) Chrome/19.0.1084.36 Safari/536.5",
    "Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1063.0 Safari/536.3",
    "Mozilla/5.0 (Windows NT 5.1) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1063.0 Safari/536.3",
    "Mozilla/4.0 (compatible; MSIE 7.0; Windows NT 5.1; Trident/4.0; SE 2.X MetaSr 1.0; SE 2.X MetaSr 1.0; .NET CLR 2.0.50727; SE
2.X MetaSr 1.0)",
    "Mozilla/5.0 (Windows NT 6.2) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1062.0 Safari/536.3",
    "Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1062.0 Safari/536.3",
    "Mozilla/4.0 (compatible; MSIE 7.0; Windows NT 5.1; 360SE)",
    "Mozilla/5.0 (Windows NT 6.1; WOW64) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1061.1 Safari/536.3",
    "Mozilla/5.0 (Windows NT 6.1) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1061.1 Safari/536.3",
    "Mozilla/5.0 (Windows NT 6.2) AppleWebKit/536.3 (KHTML, like Gecko) Chrome/19.0.1061.0 Safari/536.3",
    "Mozilla/5.0 (X11; Linux x86_64) AppleWebKit/535.24 (KHTML, like Gecko) Chrome/19.0.1055.1 Safari/535.24",
    "Mozilla/5.0 (Windows NT 6.2; WOW64) AppleWebKit/535.24 (KHTML, like Gecko) Chrome/19.0.1055.1 Safari/535.24"
]
# 设置请求延时操作

DOWNLOAD_DELAY = 1
```

7、设置 middlewares.py 文件，对请求进行处理。

```
class RandomUA(object):
# 设置随机请求头
    def process_request(self,request,spider):
        UA = random.choice(USER_AGENT)
        request.headers["user-agent"] = UA
```

8、设置爬虫的启动文件 start.py

```
1 from scrapy.cmdline import execute
2 execute("scrapy crawl hr".split())
```

9、执行效果如下。（保存为 json 数据格式的字符串到本地）


```
 1 {"position": ["25928-高级图形开发工程师（深圳总部）"], "position_type": ["技术类"], "persons": ["3"], "place": ["深圳"], "time
": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46479&keywords=&tid=0&lid=0", "work_duty": "['负
责游戏引擎图形相关特性的开发；', '负责渲染流程和算法的优化，以及相关工具的开发；', '负责图形兼容性分析以及疑难问题的分析定位工作。
']", "work_request": "['本科以上学历，精通 C/C++，具备扎实的数据结构和算法基础，熟悉常用设计模式；', '具备计算机图形学知识，熟练掌
握 3D 图形渲染技术，熟悉 OpenGL 以及 Shader 开发；', '熟练掌握 3D 游戏引擎架构， 熟悉 3D 引擎的接口和游戏制作流程；', '3 年以上 3D 引擎
（Unreal、Unity 等）开发经验，一年以上渲染相关开发和优化经验；', '深刻理解客户端框架和其他核心模块的实现，有主导过核心模块的开发经
验者优先；', '熟悉移动端 GPU/CPU 架构，有移动端渲染开发经验者优先；', '责任心强，善于沟通，对游戏前沿技术应用抱有热情。']"},
 2 {"position": ["25667-渠道销售经理（深圳）"], "position_type": ["市场类"], "persons": ["2"], "place": ["深圳"], "time": ["2018-1
2-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46485&keywords=&tid=0&lid=0", "work_duty": "['担任腾讯云渠道
经理，负责区域渠道体系建设及产品销售；', '定期拜访渠道合作伙伴，充分了解客户需求并积极跟进，制定合理方案，负责方案提示、谈判，追踪
公司相关部门的工作，保证方案的有效实施；', '维持与现有合作伙伴的良好业务关系，及时更新公司产品信息，传达企业及品牌文化。']", "work
_request": "['本科及以上学历，计算机、电信、市场营销或其它相关专业；', '软件或互联网行业五年以上相关工作经验；', '具有丰富的渠道销
售、区域管理及长尾中小企业客户覆盖经验；', '具有企业级应用软件销售经验，具有云计算及互联网行业渠道销售经验优先；', '能够有效通过渠
道覆盖中长尾客户，承担区域销售业绩；', '能够建立区域渠道体系，有效处理渠道冲突与风险防范；', '能够主导制定各种服务与激励方式，持续
提高渠道合作伙伴的满意度；', '具有出色的协调能力，良好的团队合作精神；为人诚信，工作敬业，有责任心。']"},
 3 {"position": ["28481-医疗健康 UI 开发工程师(深圳)"], "position_type": ["设计类"], "persons": ["1"], "place": ["深圳"], "time":
["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46476&keywords=&tid=0&lid=0", "work_duty": "['负责腾
讯觅影，智慧医院等相关医疗产品的前端组件的编写，web 开发工作；', '根据产品与设计要求，不断优化前端架构，改善用户体验。参与相关 UI 组
件体系的建立、维护等。']", "work_request": "['网页重构或 web 前端开发工作 2 年以上； ', '精通 HTML5，CSS3，JavaScript 构建高性能 web
应用；掌握 React 或 Vue 并有相关实战经验，掌握主流前端构建工具 grunt，gulp，webpack；', '精通 UI 组件化开发、动效开发、响应式、多终端
适配、无障碍有一定开发经验；', '有 node.js/vue/react 开发经验者优先，有前端性能、工具研发方面的实践经验优先。', '对 Web 性能、安全相
关有一定的了解； ', '有创新精神并能积极学习业界新技术，顺畅的沟通合作能力。']"},
```

4 {"position": ["SA-腾讯社交广告高级系统测试工程师（研发中心 北京）"], "position_type": ["技术类"], "persons": ["1"], "place": ["北京"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46486&keywords=&tid=0&lid=0", "work_duty": "['参与互联网软件产品测试的全流程，包括参与需求分析、设计评审，制定测试计划，设计和执行测试用例，进行缺陷跟踪和软件质量分析等；', '制定测试计划，构建测试环境，执行集成测试，回归测试等； ', '保证被测系统的质量，并通过测试流程和方法创新，努力提升研发的质量和效率。']", "work_request": "['工科、计算机或其他相关专业本科以上学历；', '熟悉 C/C++/Java 等至少一种编程语言,有 Shell 或 Ruby/PHP/Perl/Python 等使用经验者优先；', '至少 1 年以上软件开发、自动化测试工作经验；', '有性能、安全、白盒测试等专业测试领域经验者优先；', '具备互联网广告、搜索、大数据处理、分布式系统、数据库和网络等业务领域测试经验者优先；', '熟悉 Linux 或 Unix 操作系统；', '精通测试流程和测试用例设计方法,能主动进行技术钻研；', '解决复杂问题和编写自动测试工具和系统的能力；', '很强的逻辑思维能力,谈判的能力和冲突管理的能力；', '善于团队合作,理解和适应变化,以结果和行动为准则,努力追求成功。']"},
5 {"position": ["25664-政府行业交付项目经理"], "position_type": ["产品/项目类"], "persons": ["2"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46484&keywords=&tid=0&lid=0", "work_duty": "['1、负责腾讯云政府行业的项目交付管理工作；', '2、负责项目资源的组织与协调，确保项目团队各干系人及内外部合作团队的协同工作； ', '3、负责项目计划的制定、跟踪与维护，确保项目按计划完成，并解决交付中的各类问题；', '4、协助收集客户需求和用户反馈，驱动研发团队完善产品，确保项目顺利通过验收。']", "work_request": "['1、全日制统招本科及以上学历，5 年以上政府行业经验，至少深入参与 5 个政府行业大中型项目；', '2、有在大型企业工作的经历，管理过 20 人以上的项目团队，有丰富的跨部门、跨组织沟通协调经验，能够应对复杂的项目环境；', '3、熟悉研发过程，包括产品设计、需求分析、架构设计、开发、测试、运维等，熟悉敏捷开发过程；', '4、有出色的沟通能力和技巧，能够想方设法推动项目的顺利进行，有强烈的结果导向意识；', '5、具备良好的项目管理、客户关系维护能力，和优秀的沟通技巧，能妥善协调好客户、合作伙伴、内部团队的合作关系；', '6、有非常强的事业心、责任感和担当精神，有较强的抗压能力，能并行处理多个项目工作，能承受一定程度的出差或驻场工作；', '7、有 PMP、ITIL 证书者优先，信息产业部系统集成项目经理证书者优先。']"},
6 {"position": ["PCG14-应用宝数据挖掘算法工程师（深圳）"], "position_type": ["技术类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46483&keywords=&tid=0&lid=0", "work_duty": "['负责提供合适的推荐算法模型；', '负责研究业内领先的技术，结合腾讯各个业务平台的数据，根据应用中心和社交渠道这两个场景给出具体的实验数据，并且评估结果；', '负责根据不同的算法模型，上报业务需要的统计数据，协助各种算法的实施；', '研究已有算法的瓶颈，提出合理的改进措施和解决方案。']", "work_request": "['计算机、应用数学、人工智能、模式识别、统计、自控等专业的硕士或者博士优先；', '2 年以上相关工作经验；', '对机器学习、数据挖掘算法及其在互联网上的应用有比较深入的理解；', '熟悉掌握 C/C++语言；', '有大规模分布式计算平台的使用和并行算法开发经验；', '严密的数学思维、突出的分析和归纳能力、优秀的沟通表达能力；', '有互联网广告，电商，搜索等方面推荐经验优先。']"},
7 {"position": ["19867-游戏后台开发工程师（深圳）"], "position_type": ["技术类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46482&keywords=&tid=0&lid=0", "work_duty": "['负责游戏后台架构设计；', '负责游戏后台系统模块以及新特性开发；', '负责服务器性能优化和体验优化。']", "work_request": "['2 年以上游戏服务器后台工作经验，有完整的项目经验；', '扎实的编程基础，对高在线大并发游戏后台架构有一定认识；', '熟悉 Unix/Linux 操作系统下的 C/C++开发；', '熟悉 TCP/IP 协议相关知识，熟悉网络编程，熟悉数据库；', '了解游戏服务器架构及性能优化方法；', '具备良好的分析解决问题能力，能独立承担后台逻辑系统开发工作；', '高度的责任心、良好的沟通能力和团队合作精神。']"},

8 {"position": ["TME-全民 K 歌项目经理（深圳）"], "position_type": ["产品/项目类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46478&keywords=&tid=0&lid=0", "work_duty": "['负责全民 K 歌版本计划制定，风险监控，过程跟踪，保障版本目标的实现；', '负责 FT 内目标确认，目标拆解，资源分配以及目标达成情况跟进，推动各角色协同工作；', '发现、总结、跟踪过程问题，推动团队各环节持续改进，提高效率。']", "work_request": "['本科以上学历，计算机或相关专业；', '3 年以上软件项目管理经验，有互联网、软件领域技术开发经验优先；', '精通软件项目过程管理，对敏捷项目管理有实际应用经验及深刻理解；', '具有良好的执行力和责任心，能推动项目团队朝目标前进；', '具有丰富的与人沟通、交流和组织能力，出色的团队合作精神；']"},
9 {"position": ["25928-高级语音算法工程师（上海）"], "position_type": ["技术类"], "persons": ["1"], "place": ["上海"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46477&keywords=&tid=0&lid=0", "work_duty": "['负责游戏语音算法优化；', '负责语音前沿技术研究；', '负责游戏语音现网版本算法维护升级。']", "work_request": "['本科及以上学历；', '熟悉 PC/Android/iOS SDK 任一平台 C/C++开发，性能优化； ', '熟悉数字信号处理，数学功底扎实，熟悉 MATLAB 仿真； ', '熟悉语音前处理算法 AEC,AGC,VAD,NS,CNG,JitterBuffer,Mix 等算法；', '熟悉常见 Codec,Opus/AAC/Speex 等;', '有 AI 语音前处理经验优先；', '熟悉 WebRTC,Speex,Opus 等开源代码。']"},
10 {"position": ["HY-游戏发行/运营培训生（深圳）"], "position_type": ["产品/项目类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46481&keywords=&tid=0&lid=0", "work_duty": "['游戏发行/运营培训生项目致力于培养高潜力的游戏运营人才，以满足快速增长游戏业务需求；', '项目采用定制化的培养方式，通过专班学习，名师辅导和项目实战，提升学员的产品 sense、运营能力及通用素质，使学员成为优秀的游戏发行/运营人才。', '协助项目制作人与研发商共同制定运营目标和工作计划，约定的各阶段游戏优化、运营开发和运营支持工作；', '推动游戏研发商的日常沟通，密切关注研发和运营筹备进度同时提供必要协助；', '指导并支持项目组内不同职能员工的日常工作，推动合作部门的目标和工作计划制定；', '根据项目需求，制定并推广项目流程规范，确保项目有序推进；', '及时发现并跟踪解决项目问题，有效管理项目风险。']", "work_request": "['热爱并乐于体验游戏，对研发与运营有一定的了解，保持强烈的好奇心和求知欲；', '优秀的中英文读写能力；', '积极主动，能够承受高压的工作。']"},
11 {"position": ["25928-高级图形开发工程师（上海）"], "position_type": ["技术类"], "persons": ["3"], "place": ["上海"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46480&keywords=&tid=0&lid=0", "work_duty": "['负责游戏引擎图形相关特性的开发；', '负责渲染流程和算法的优化，以及相关工具的开发；', '负责图形兼容性分析以及疑难问题的分析定位工作。']", "work_request": "['本科以上学历，精通 C/C++，具备扎实的数据结构和算法基础，熟悉常用设计模式；', '具备计算机图形学知识，熟练掌握 3D 图形渲染技术，熟悉 OpenGL 以及 Shader 开发；', '熟练掌握 3D 游戏引擎架构， 熟悉 3D 引擎的接口和游戏制作流程；', '3 年以上 3D 引擎（Unreal、Unity 等）开发经验，一年以上渲染相关开发和优化经验；', '深刻理解客户端框架和其他核心模块的实现，有主导过核心模块的开发经验者优先；', '熟悉移动端 GPU/CPU 架构，有移动端渲染开发经验者优先；', '责任心强，善于沟通，对游戏前沿技术应用抱有热情。']"},
12 {"position": ["28481-健康保险行业合作高级经理（深圳）"], "position_type": ["市场类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46474&keywords=&tid=0&lid=0", "work_duty": "['1、负责商业保险行业客户资源拓展（包括不限于保险公司、创新保险平台、行业协会等专业领域）；', '2、拓展相关行业合作伙伴以及合作机构，整合公司已有产品和资源，形成场景化的创新解决方案；', '3、搜集整理健康保险行业的市场动态、政策变动等行业信息，解读反馈助推业务策略制定；', '4、整合资源，设计制定并推进商业合作方案落地，有效撬动行业资源合作。']", "work_request": "['1、全日制本科及以上学历，三年以上健康保险领域工作经验；', '2、熟悉保险行业，有健康险创新产品运营经验或创新平台运营经验； ', '3、具备良好的沟通表达能力，清晰的思维逻辑，敏锐的洞察力，较强的自驱力和执行力； ', '4、对工作有高度的责任心和激情，注重团队合作，适应频繁差旅需求。']"},

13 {"position": ["25928-前端测试开发工程师（深圳）"], "position_type": ["技术类"], "persons": ["1"], "place": ["深圳"], "time": ["2018-12-19"], "detail_link": "https://hr.tencent.com/position_detail.php?id=46473&keywords=&tid=0&lid=0", "work_duty": "['负责平台类软件的测试开发工作；', '负责平台组件的接口测试、单元测试工作；', '能够在关键技术上给予团队技术指引和支持；', '按时完成安排的移动端开发任务；', '负责与项目组之间的协调，推动工作，帮助项目组推动整个项目质量的提升。']", "work_request": "['本科及以上学历，计算机相关专业，开发或者测试开发出身，有软件开发的基础；', '2-3 年以上软件行业或者互联网行业经验，熟悉 Windows 编程或 Android/iOS 编程；', '熟悉软件开发流程，熟悉 Android/iOS 环境下自动化测试技术；', '扎实的测试用例设计能力，熟悉主流自动化方法；', '具备扎实的 C++、C 或 Object-C 程序设计基础。', '有以下任意一项经验者优先：', '较强的 DEBUG 能力；', '有 Android、iOS 产品自动化测试经验。']"},
.....

002、python 爬虫+数据可视化项目（一）

爬取目标：中国天气网（起始 **url：http://www.weather.com.cn/textFC/hb.shtml#**）
爬取内容：全国实时温度最低的十个城市气温排行榜
使用工具：**requests** 库实现发送请求、获取响应。
beautifulsoup 实现数据解析、提取和清洗
pyechart 模块实现数据可视化
爬取结果：柱状图可视化展示：

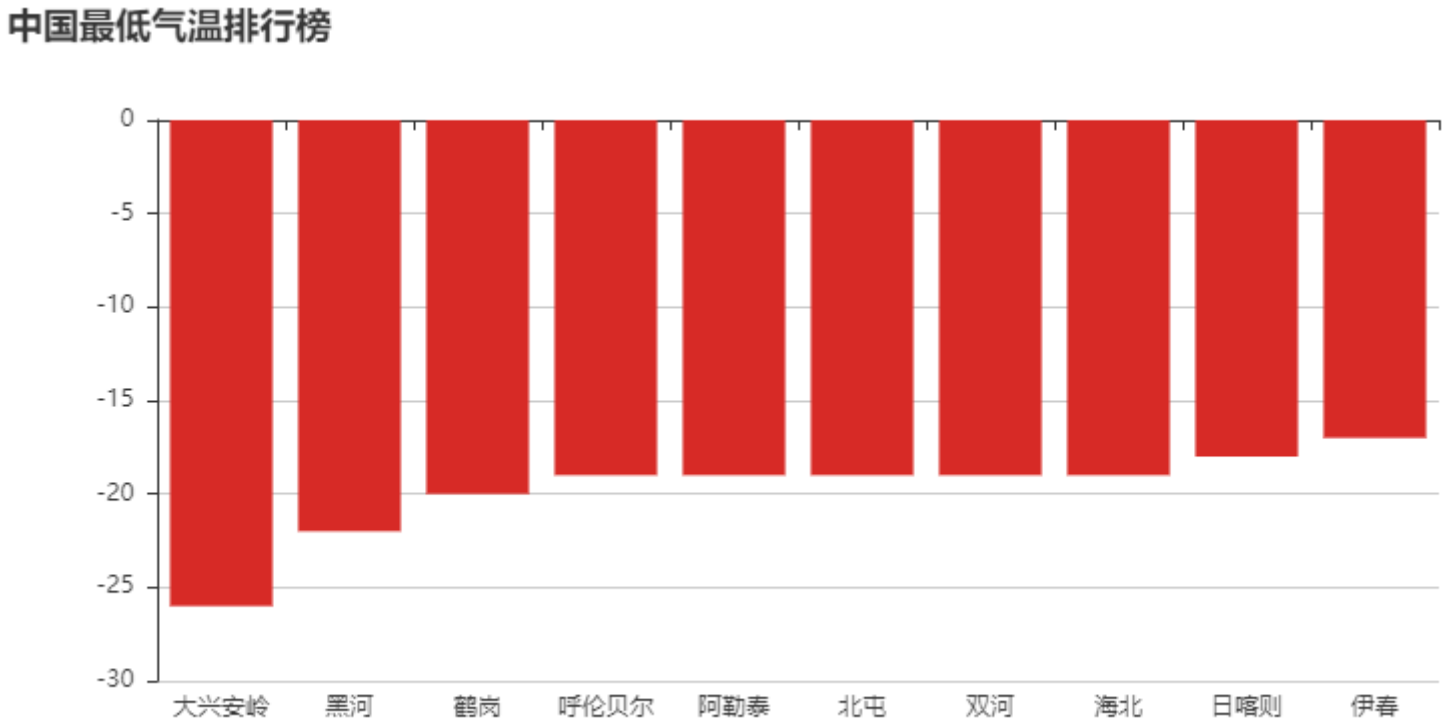

直接放代码（详细说明在注释里，欢迎同行相互交流、学习～）：

```
1 import requests
2 from bs4 import BeautifulSoup
3 from pyecharts import Bar
4
5 ALL_DATA = []
```

```python
def send_parse_urls(start_urls):
    headers = {
    "User-Agent": "Mozilla/5.0 (compatible; YandexBot/3.0; +http://yandex.com/bots)"
    }
    for start_url in start_urls:
        response = requests.get(start_url,headers=headers)
        # 编码问题的解决
        response = response.text.encode("raw_unicode_escape").decode("utf-8")
        soup = BeautifulSoup(response,"html5lib") #lxml 解析器：性能比较好，html5lib：适合页面结构比较混乱的
        div_tatall = soup.find("div",class_="conMidtab") #find() 找符合要求的第一个元素
        tables = div_tatall.find_all("table") #find_all() 找到符合要求的所有元素的列表
        for table in tables:
            trs = table.find_all("tr")
            info_trs = trs[2:]
            for index,info_tr in enumerate(info_trs): # 枚举函数，可以获得索引
                # print(index,info_tr)
                # print("="*30)
                city_td = info_tr.find_all("td")[0]
                temp_td = info_tr.find_all("td")[6]
                # if 的判断的 index 的特殊情况应该在一般情况的后面，把之前的数据覆盖
                if index==0:
                    city_td = info_tr.find_all("td")[1]
                    temp_td = info_tr.find_all("td")[7]
                city=list(city_td.stripped_strings)[0]
                temp=list(temp_td.stripped_strings)[0]
                ALL_DATA.append({"city":city,"temp":temp})
    return ALL_DATA

def get_start_urls():
    start_urls = [
       "http://www.weather.com.cn/textFC/hb.shtml",
        "http://www.weather.com.cn/textFC/db.shtml",
        "http://www.weather.com.cn/textFC/hd.shtml",
        "http://www.weather.com.cn/textFC/hz.shtml",
```

```
        "http://www.weather.com.cn/textFC/hn.shtml",
        "http://www.weather.com.cn/textFC/xb.shtml",
        "http://www.weather.com.cn/textFC/xn.shtml",
        "http://www.weather.com.cn/textFC/gat.shtml",
    ]
    return start_urls

def main():
    """
    主程序逻辑
    展示全国实时温度最低的十个城市气温排行榜的柱状图
    """
    # 1 获取所有起始 url
    start_urls = get_start_urls()
    # 2 发送请求获取响应、解析页面
    data = send_parse_urls(start_urls)
    # print(data)
    # 4 数据可视化
        #1 排序
    data.sort(key=lambda data:int(data["temp"]))
        #2 切片，选择出温度最低的十个城市和温度值
    show_data = data[:10]
        #3 分出城市和温度
    city = list(map(lambda data:data["city"],show_data))
    temp = list(map(lambda data:int(data["temp"]),show_data))
        #4 创建柱状图、生成目标图
    chart = Bar("中国最低气温排行榜") #需要安装 pyechart 模块
    chart.add("",city,temp)
    chart.render("tempture.html")

if __name__ == '__main__':
    main()
```

003、python 多线程爬虫+批量下载斗图啦图片项目（关注、持续更新）

python 多线程爬虫项目（）

爬取目标：斗图啦（起始 url：http://www.doutula.com/photo/list/?page=1）

爬取内容：斗图啦全网图片

使用工具：**requests** 库实现发送请求、获取响应。

xpath 实现数据解析、提取和清洗

threading 模块实现多线程爬虫

爬取结果：

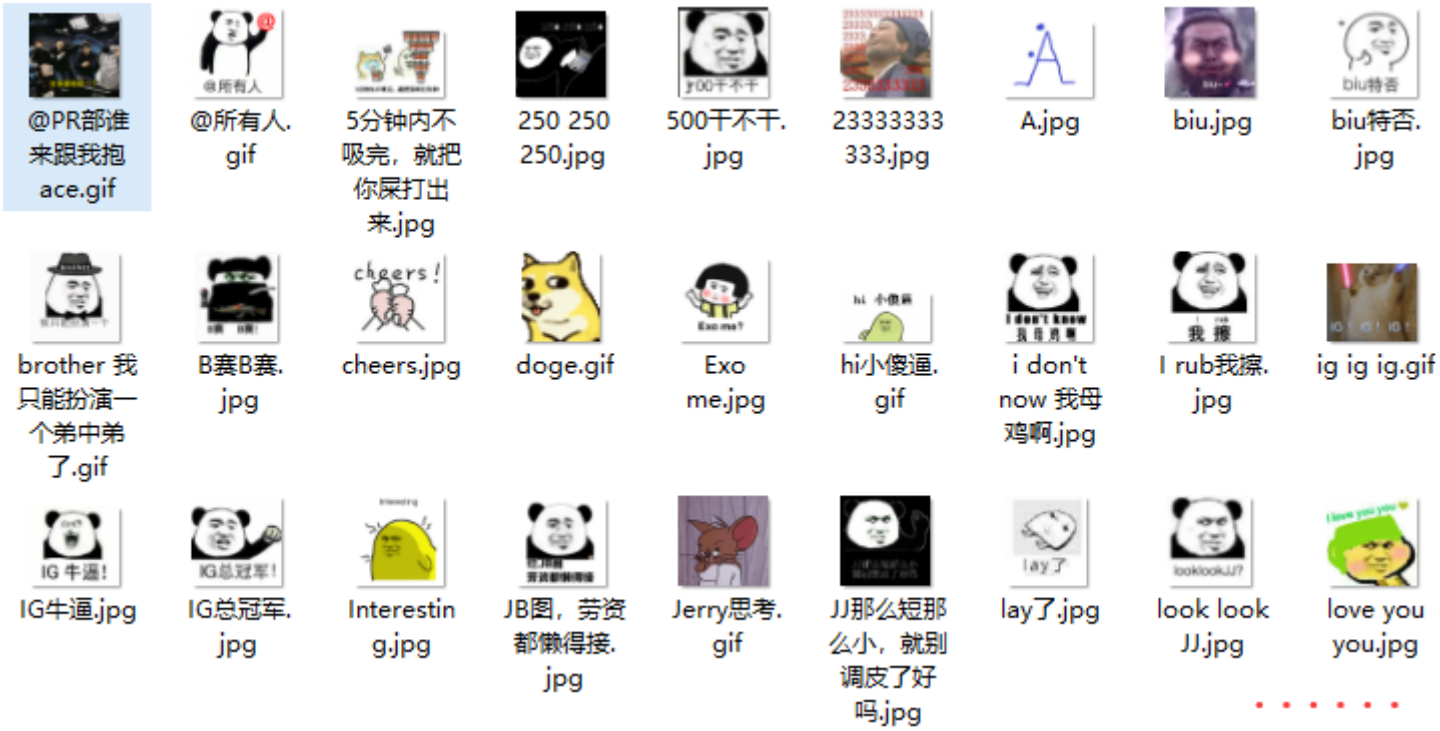

思路：由于该爬虫存在网络密集 **IO** 和磁盘密集 **IO**，存在大量等待时间，遂采用多线程方式爬取。

设计：本文采用多为结构化代码的面向对象封装设计思路，使用生产消费者模型，完成多线程的调度、爬取。

直接放代码（详细说明在注释里，欢迎同行相互交流、学习~）：

```
1 import os
2 import threading
```

```python
import re
from queue import Queue
import requests
from urllib import request
from lxml import etree

# 定义一个全局变量，存储请求头 headers 数据
headers = {
    "User-Agent": "Mozilla/5.0 (compatible; YandexBot/3.0; +http://yandex.com/bots)"
}

class Producter(threading.Thread):
    """
    生产者模型：负责从起始 url 队列中提取 url，进行解析，将得到的图片地址放入 img 图片队列中
    """
    def __init__(self, page_queue, img_queue, *args, **kwargs):
        # 改写父类 threading.Thread 的__init__方法，添加默认值
        super(Producter, self).__init__(*args, **kwargs)
        # 添加对象属性
        self.page_queue = page_queue
        self.img_queue = img_queue

    def run(self):
        """
        实现消费者模型的主要业务逻辑
        """
        while True:
            # 当请求队列为空，生产者停止生产
            if self.page_queue.empty():
                break
            # 获取起始 url 队列的对象，进行页面解析
            url = self.page_queue.get()
            self.parse_url(url)

```

```
37      def parse_url(self, url):
38          """
39          实现解析指定页面的功能
40          :param url: 传入待处理的页面 url
41          """
42          response = requests.get(url=url, headers=headers)
43          html = etree.HTML(response.text)
44          # 使用 lxml 库里 HTML 解析器进行数据解析，利用 xpath 语法解析得到指定数据，返回一个 element 对象列表
45          url_gifs = html.xpath("//div[@class='page-content text-center']//img[@class!='gif']")
46          for url_gif in url_gifs:
47              # element.get(属性名)可以获取属性值
48              url_name = url_gif.get("alt")
49              # 正则表达式替换非法字符
50              url_name = re.sub(r"[\!! \.\?? ]", "", url_name).strip()
51              url_link = url_gif.get("data-original")
52              # os 模块中 os.path.splitext()可以获取 url 的后缀名
53              url_suffix = os.path.splitext(url_link)[1]
54              filename = url_name + url_suffix
55              # 队列的 put（）里面传的是元组或者列表
56              self.img_queue.put((url_link, filename))
57
58  class Consumer(threading.Thread):
59      """
60      消费者模型的主要业务逻辑
61      """
62
63      def __init__(self, page_queue, img_queue, *args, **kwargs):
64          super(Consumer, self).__init__(*args, **kwargs)
65          self.page_queue = page_queue
66          self.img_queue = img_queue
67
68      def run(self):
69          """
70          实现读取图片 url 内容的功能
```

```
71          """
72          while True:
73              if self.page_queue.empty() and self.img_queue.empty():
74                  break
75              url, filename = self.img_queue.get()
76              # urllib 库里面的 request 模块可以读取图片 url 内容
77              request.urlretrieve(url, "GIF/" + filename)
78              # 控制台输出提示信息
79              print(filename + "-------下载完成！")
80
81  def main():
82      # 创建 page 队列，存放请求的起始 url;创建 img 队列，存放图片 data 的 url
83      page_queue = Queue(100) # 设置队列的最大存储数量
84      img_queue = Queue(1000) # 设置队列的最大存储数量
85      for i in range(100):
86          start_url_format = "http://www.doutula.com/photo/list/?page={}".format(i)
87          # print(start_url_format) #调试代码用
88          page_queue.put(start_url_format) #将获取的起始 url 放入队列中
89      # 生成多线程对象（多个生产者、消费者）。实现发送请求，获取响应，解析页面，获取数据
90      for i in range(10):
91          t = Producter(page_queue, img_queue)
92          t.start()
93      for i in range(10):
94          t = Consumer(page_queue, img_queue)
95          t.start()
96
97  if __name__ == '__main__':
98      main()
```

004、python 爬虫项目(scrapy-redis 分布式爬取房天下租房信息)
python 爬虫 scrapy 项目（二）

爬取目标：房天下全国租房信息网站（起始 url：http://zu.fang.com/cities.aspx）
爬取内容：城市；名字；出租方式；价格；户型；面积；地址；交通
反反爬措施：设置随机 user-agent、设置请求延时操作、

1、开始创建项目

```
1 scrapy startproject fang
```

2、进入 **fang** 文件夹，执行启动 **spider** 爬虫文件代码，编写爬虫文件。

```
1 scrapy genspider zufang "zu.fang.com"
```

命令执行完，用 Python 最好的 IDE---pycharm 打开该文件目录

3、编写该目录下的 **items.py** 文件，设置你需要爬取的字段。

```
 1 import scrapy
 2
 3
 4 class HomeproItem(scrapy.Item):
 5     # define the fields for your item here like:
 6     # name = scrapy.Field()
 7
 8     city = scrapy.Field()  #城市
 9     title = scrapy.Field()  # 名字
10     rentway = scrapy.Field()  # 出租方式
11     price = scrapy.Field()    #价格
12     housetype = scrapy.Field()  # 户型
13     area = scrapy.Field()  # 面积
14     address = scrapy.Field()  # 地址
15     traffic = scrapy.Field()  # 交通
```

4、进入 **spiders** 文件夹，打开 **hr.py** 文件,开始编写爬虫文件

```
 1 # -*- coding: utf-8 -*-
 2 import scrapy
 3 from homepro.items import HomeproItem
 4 from scrapy_redis.spiders import RedisCrawlSpider
 5 # scrapy.Spider
 6 class HomeSpider(RedisCrawlSpider):
 7     name = 'home'
 8     allowed_domains = ['zu.fang.com']
```

```
    # start_urls = ['http://zu.fang.com/cities.aspx']

    redis_key = 'homespider:start_urls'
    def parse(self, response):
        hrefs = response.xpath('//div[@class="onCont"]/ul/li/a/@href').extract()
        for href in hrefs:
            href = 'http:'+ href
            yield scrapy.Request(url=href,callback=self.parse_city,dont_filter=True)


    def parse_city(self, response):
        page_num = response.xpath('//div[@id="rentid_D10_01"]/span[@class="txt"]/text()').extract()[0].strip('共页')
        # print('*' * 100)
        # print(page_num)
        # print(response.url)

        for page in range(1, int(page_num)):
            if page == 1:
                url = response.url
            else:
                url = response.url + 'house/i%d' % (page + 30)
            print('*' * 100)
            print(url)
            yield scrapy.Request(url=url, callback=self.parse_houseinfo, dont_filter=True)

    def parse_houseinfo(self, response):
        divs = response.xpath('//dd[@class="info rel"]')
        for info in divs:
            city = info.xpath('//div[@class="guide rel"]/a[2]/text()').extract()[0].rstrip("租房")
            title = info.xpath('.//p[@class="title"]/a/text()').extract()[0]
            rentway = info.xpath('.//p[@class="font15 mt12 bold"]/text()')[0].extract().replace(" ", '').lstrip('\r\n')
            housetype = info.xpath('.//p[@class="font15 mt12 bold"]/text()')[1].extract().replace(" ", '')
            area = info.xpath('.//p[@class="font15 mt12 bold"]/text()')[2].extract().replace(" ", '')
            addresses = info.xpath('.//p[@class ="gray6 mt12"]//span/text()').extract()
```

```
            address = '-'.join(i for i in addresses)
            try:
                des = info.xpath('.//p[@class ="mt12"]//span/text()').extract()
                traffic = '-'.join(i for i in des)
            except Exception as e:
                traffic = "暂无详细信息"

            p_name = info.xpath('.//div[@class ="moreInfo"]/p/text()').extract()[0]
            p_price = info.xpath('.//div[@class ="moreInfo"]/p/span/text()').extract()[0]
            price = p_price + p_name

            item = HomeproItem()
            item['city'] = city
            item['title'] = title
            item['rentway'] = rentway
            item['price'] = price
            item['housetype'] = housetype
            item['area'] = area
            item['address'] = address
            item['traffic'] = traffic
            yield item
```

5、设置 setting.py 文件，配置 scrapy 运行的相关内容

```
# 指定使用 scrapy-redis 的调度器
SCHEDULER = "scrapy_redis.scheduler.Scheduler"

# 指定使用 scrapy-redis 的去重
DUPEFILTER_CLASS = 'scrapy_redis.dupefilter.RFPDupeFilter'

# 指定排序爬取地址时使用的队列，
# 默认的 按优先级排序(Scrapy 默认)，由 sorted set 实现的一种非 FIFO、LIFO 方式。
SCHEDULER_QUEUE_CLASS = 'scrapy_redis.queue.SpiderPriorityQueue'

REDIS_HOST = '10.8.153.73'
REDIS_PORT = 6379
```

```
13 # 是否在关闭时候保留原来的调度器和去重记录，True=保留，False=清空
14 SCHEDULER_PERSIST = True
```

6、然后把代码发给其他附属机器,分别启动.子程序 **redis** 链接主服务器 **redis**。

```
1 redis-cli   -h  主服务器 ip
```

7、主服务器先启动 **redis-server**，再启动 **redis-cli**

```
1 lpush homespider:start_urls   起始的 url
```

188、你常用的 mysql 引擎有哪些？各引擎间有什么区别？

主要 MyISAM 与 InnoDB 两个引擎，其主要区别如下：
一、InnoDB 支持事务，MyISAM 不支持，这一点是非常之重要。事务是一种高级的处理方式，如在一些列增删改中只要哪个出错还可以回滚还原，而 MyISAM 就不可以了；
二、MyISAM 适合查询以及插入为主的应用，InnoDB 适合频繁修改以及涉及到安全性较高的应用；
三、InnoDB 支持外键，MyISAM 不支持；
四、MyISAM 是默认引擎，InnoDB 需要指定；
五、InnoDB 不支持 FULLTEXT 类型的索引；
六、InnoDB 中不保存表的行数，如 select count(*) from table 时，InnoDB；需要扫描一遍整个表来计算有多少行，但是 MyISAM 只要简单的读出保存好的行数即可。注意的是，当 count(*)语句包含 where 条件时 MyISAM 也需要扫描整个表；
七、对于自增长的字段，InnoDB 中必须包含只有该字段的索引，但是在 MyISAM 表中可以和其他字段一起建立联合索引；
八、清空整个表时，InnoDB 是一行一行的删除，效率非常慢。MyISAM 则会重建表；
九、InnoDB 支持行锁（某些情况下还是锁整表，如 update table set a=1 where user like '%lee%'

189、什么是关联查询，有哪些？

将多个表联合起来进行查询，主要有内连接、左连接、右连接、全连接（外连接）

190、数据库的优化？

1. 优化索引、SQL 语句、分析慢查询；
2. 设计表的时候严格根据数据库的设计范式来设计数据库；
3. 使用缓存，把经常访问到的数据而且不需要经常变化的数据放在缓存中，能节约磁盘 IO；
4. 优化硬件；采用 SSD，使用磁盘队列技术(RAID0,RAID1,RDID5)等；

5. 采用 MySQL 内部自带的表分区技术，把数据分层不同的文件，能够提高磁盘的读取效率；
6. 垂直分表；把一些不经常读的数据放在一张表里，节约磁盘 I/O；
7. 主从分离读写；采用主从复制把数据库的读操作和写入操作分离开来；
8. 分库分表分机器（数据量特别大），主要的的原理就是数据路由；
9. 选择合适的表引擎，参数上的优化；
10. 进行架构级别的缓存，静态化和分布式；
11. 不采用全文索引；
12. 采用更快的存储方式，例如 NoSQL 存储经常访问的数据

191、简述 RabbitMQ、Kafka、ZeroMQ 的区别？

https://blog.csdn.net/zhailihua/article/details/7899006

192、RabbitMQ 如何在消费者获取任务后未处理完前就挂掉时，保证数据不丢失？

为了预防消息丢失，rabbitmq 提供了 ack
即工作进程在收到消息并处理后，发送 ack 给 rabbitmq，告知 rabbitmq 这时候可以把该消息从队列中删除了。
如果工作进程挂掉 了，rabbitmq 没有收到 ack，那么会把该消息 重新分发给其他工作进程。
不需要设置 timeout，即使该任务需要很长时间也可以处理。

ack 默认是开启的，工作进程显示指定了 no_ack=True

193、RabbitMQ 如何对消息做持久化？

1、创建队列和发送消息时将设置 durable=Ture，如果在接收到消息还没有存储时，消息也有可能丢失，就必须配置 publisher confirm
channel.queue_declare(queue='task_queue', durable=True)

2、返回一个 ack，进程收到消息并处理完任务后，发给 rabbitmq 一个 ack 表示任务已经完成，可以删除该任务

3、镜像队列：将 queue 镜像到 cluster 中其他的节点之上。
在该实现下，如果集群中的一个节点失效了，queue 能自动地切换到镜像中的另一个节点以保证服务的可用性

194、RabbitMQ 如何控制消息被消费的顺序？

默认消息队列里的数据是按照顺序被消费者拿走，
例如：消费者 1 去队列中获取奇数序列的任务，消费者 2 去队列中获取偶数序列的任务。

channel.basic_qos(prefetch_count=1)
表示谁来谁取，不再按照奇偶数排列（同时也保证了公平的消费分发）

195、以下 RabbitMQ 的 exchange type 分别代表什么意思？如：fanout、direct、topic。

```
amqp 协议中的核心思想就是生产者和消费者隔离，生产者从不直接将消息发送给队列。
生产者通常不知道是否一个消息会被发送到队列中，只是将消息发送到一个交换机。
先由 Exchange 来接收，然后 Exchange 按照特定的策略转发到 Queue 进行存储。
同理，消费者也是如此。Exchange 就类似于一个交换机，转发各个消息分发到相应的队列中。
------------------------------------------------
type=fanout 类似发布者订阅者模式，会为每一个订阅者创建一个队列，而发布者发布消息时，会将消息放置在所有相关队列中
type=direct 队列绑定关键字，发送者将数据根据关键字发送到消息 exchange，exchange 根据 关键字 判定应该将数据发送至指定队列。
type=topic  队列绑定几个模糊的关键字，之后发送者将数据发送到 exchange，exchange 将传入”路由值“和 ”关键字“进行匹配，匹配成功，
则将数据发送到指定队列。
------------------------------------------------
发送者路由值                队列中
old.boy.python          old.*  -- 不匹配     *表示匹配一个
old.boy.python          old.#  -- 匹配       #表示匹配 0 个或多个
```

196、简述 celery 是什么以及应用场景？

```
# Celery 是由 Python 开发的一个简单、灵活、可靠的处理大量任务的分发系统，
# 它不仅支持实时处理也支持任务调度。
# http://www.cnblogs.com/wupeiqi/articles/8796552.html
```

197、简述 celery 运行机制。

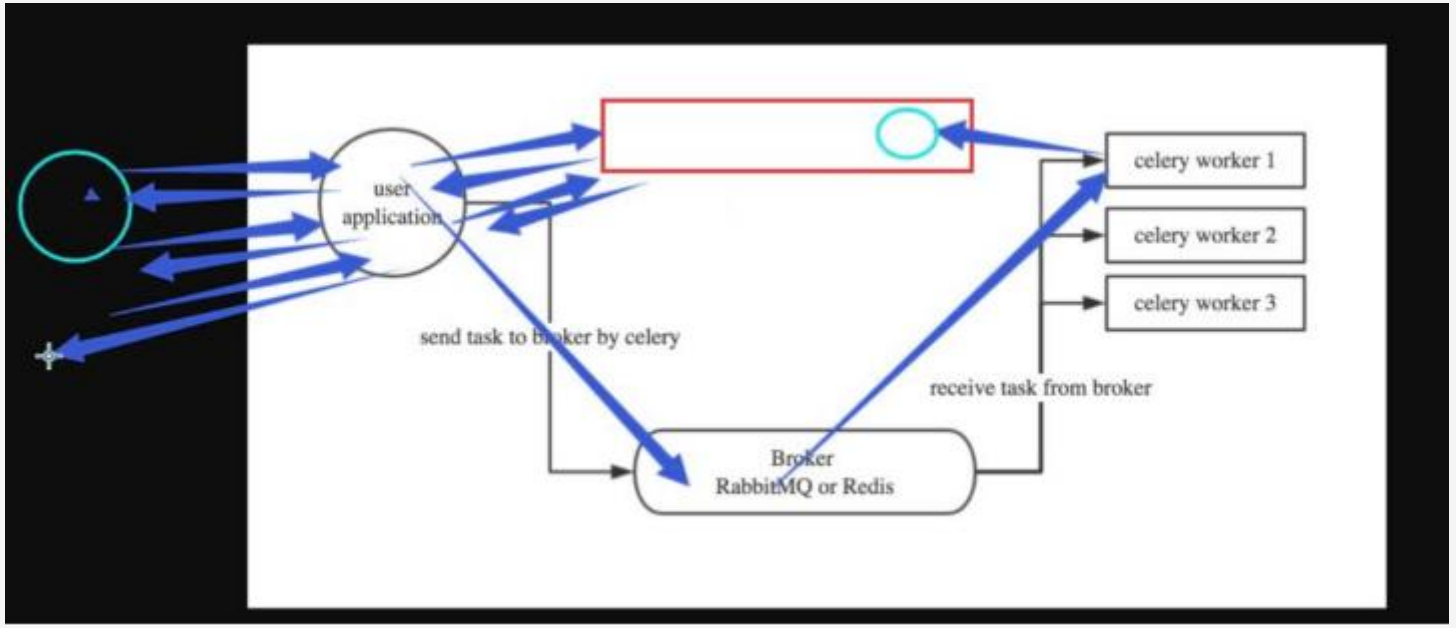

198、celery 如何实现定时任务？

```
# celery 实现定时任务
启用 Celery 的定时任务需要设置 CELERYBEAT_SCHEDULE 。
CELERYBEAT_SCHEDULE='djcelery.schedulers.DatabaseScheduler'#定时任务
'创建定时任务'
# 通过配置 CELERYBEAT_SCHEDULE：
#每 30 秒调用 task.add
from datetime import timedelta
CELERYBEAT_SCHEDULE = {
    'add-every-30-seconds': {
        'task': 'tasks.add',
        'schedule': timedelta(seconds=30),
        'args': (16, 16)
    },
}
```

199、简述 celery 多任务结构目录

```
pro_cel
```

```
    ├─── celery_tasks      # celery 相关文件夹
    │    ├─── celery.py     # celery 连接和配置相关文件
    │    └─── tasks.py      #  所有任务函数
    ├─── check_result.py  # 检查结果
    └─── send_task.py      # 触发任务
```

200、celery 中装饰器 @app.task 和 @shared_task 的区别？

```
# 一般情况使用的是从 celeryapp 中引入的 app 作为的装饰器：@app.task
# django 那种在 app 中定义的 task 则需要使用@shared_task
```

201、简述 seleninu 模块的作用及基本使用?

Selenium 是一个用于 Web 应用程序测试的工具，
他的测试直接运行在浏览器上，模拟真实用户，按照代码做出点击、输入、打开等操作

爬虫中使用他是为了解决 requests 无法解决 javascript 动态问题

202、scrapy 框架中各组件的工作流程？

#1、生成初始的 Requests 来爬取第一个 URLS，并且标识一个回调函数
第一个请求定义在 start_requests()方法内默认从 start_urls 列表中获得 url 地址来生成 Request 请求，
默认的回调函数是 parse 方法。回调函数在下载完成返回 response 时自动触发
#2、在回调函数中，解析 response 并且返回值
返回值可以 4 种：
    a、包含解析数据的字典
    b、Item 对象
    c、新的 Request 对象（新的 Requests 也需要指定一个回调函数）
    d、或者是可迭代对象（包含 Items 或 Request）
#3、在回调函数中解析页面内容
通常使用 Scrapy 自带的 Selectors，但很明显你也可以使用 Beutifulsoup，lxml 或其他你爱用啥用啥。
#4、最后，针对返回的 Items 对象将会被持久化到数据库
    通过 Item Pipeline 组件存到数据库
    或者导出到不同的文件（通过 Feed exports）
http://www.cnblogs.com/wupeiqi/articles/6229292.html

203、在 scrapy 框架中如何设置代理（两种方法）？

方式一：内置添加代理功能

```
# -*- coding: utf-8 -*-
import os
```

```
import scrapy
from scrapy.http import Request

class ChoutiSpider(scrapy.Spider):
    name = 'chouti'
    allowed_domains = ['chouti.com']
    start_urls = ['https://dig.chouti.com/']

    def start_requests(self):
        os.environ['HTTP_PROXY'] = "http://192.168.11.11"

        for url in self.start_urls:
            yield Request(url=url,callback=self.parse)

    def parse(self, response):
        print(response)
```

方式二：自定义下载中间件

```
import random
import base64
import six
def to_bytes(text, encoding=None, errors='strict'):
    """Return the binary representation of `text`. If `text`
    is already a bytes object, return it as-is."""
    if isinstance(text, bytes):
        return text
    if not isinstance(text, six.string_types):
        raise TypeError('to_bytes must receive a unicode, str or bytes '
                        'object, got %s' % type(text).__name__)
    if encoding is None:
        encoding = 'utf-8'
    return text.encode(encoding, errors)

class MyProxyDownloaderMiddleware(object):
```

```
    def process_request(self, request, spider):
        proxy_list = [
            {'ip_port': '111.11.228.75:80', 'user_pass': 'xxx:123'},
            {'ip_port': '120.198.243.22:80', 'user_pass': ''},
            {'ip_port': '111.8.60.9:8123', 'user_pass': ''},
            {'ip_port': '101.71.27.120:80', 'user_pass': ''},
            {'ip_port': '122.96.59.104:80', 'user_pass': ''},
            {'ip_port': '122.224.249.122:8088', 'user_pass': ''},
        ]
        proxy = random.choice(proxy_list)
        if proxy['user_pass'] is not None:
            request.meta['proxy'] = to_bytes("http://%s" % proxy['ip_port'])
            encoded_user_pass = base64.encodestring(to_bytes(proxy['user_pass']))
            request.headers['Proxy-Authorization'] = to_bytes('Basic ' + encoded_user_pass)
        else:
            request.meta['proxy'] = to_bytes("http://%s" % proxy['ip_port'])
```

配置：

```
    DOWNLOADER_MIDDLEWARES = {
       # 'xiaohan.middlewares.MyProxyDownloaderMiddleware': 543,
    }
```

204、scrapy 框架中如何实现大文件的下载？

```
from twisted.web.client import Agent, getPage, ResponseDone, PotentialDataLoss
from twisted.internet import defer, reactor, protocol
from twisted.web._newclient import Response
from io import BytesIO

class _ResponseReader(protocol.Protocol):
    def __init__(self, finished, txresponse, file_name):
        self._finished = finished
        self._txresponse = txresponse
        self._bytes_received = 0
```

```
        self.f = open(file_name, mode='wb')
    def dataReceived(self, bodyBytes):
        self._bytes_received += len(bodyBytes)
        # 一点一点的下载
        self.f.write(bodyBytes)
        self.f.flush()
    def connectionLost(self, reason):
        if self._finished.called:
            return
        if reason.check(ResponseDone):
            # 下载完成
            self._finished.callback((self._txresponse, 'success'))
        elif reason.check(PotentialDataLoss):
            # 下载部分
            self._finished.callback((self._txresponse, 'partial'))
        else:
            # 下载异常
            self._finished.errback(reason)
        self.f.close()
```

205、scrapy 中如何实现限速？

```
http://scrapy-chs.readthedocs.io/zh_CN/1.0/topics/autothrottle.html
```

206、scrapy 中如何实现暂停爬虫？

```
# 有些情况下，例如爬取大的站点，我们希望能暂停爬取，之后再恢复运行。
# Scrapy 通过如下工具支持这个功能:
一个把调度请求保存在磁盘的调度器
一个把访问请求保存在磁盘的副本过滤器[duplicates filter]
一个能持续保持爬虫状态(键/值对)的扩展
Job 路径
要启用持久化支持，你只需要通过 JOBDIR 设置 job directory 选项。
这个路径将会存储所有的请求数据来保持一个单独任务的状态(例如：一次 spider 爬取(a spider run))。
必须要注意的是，这个目录不允许被不同的 spider 共享，甚至是同一个 spider 的不同 jobs/runs 也不行。
也就是说，这个目录就是存储一个 单独 job 的状态信息。
```

020、scrapy 中如何进行自定制命令？

在 spiders 同级创建任意目录，如：commands
在其中创建'crawlall.py'文件（此处文件名就是自定义的命令）

```
from scrapy.commands import ScrapyCommand
    from scrapy.utils.project import get_project_settings
    class Command(ScrapyCommand):
        requires_project = True
        def syntax(self):
            return '[options]'
        def short_desc(self):
            return 'Runs all of the spiders'
        def run(self, args, opts):
            spider_list = self.crawler_process.spiders.list()
            for name in spider_list:
                self.crawler_process.crawl(name, **opts.__dict__)
            self.crawler_process.start()
```

在'settings.py'中添加配置'COMMANDS_MODULE = '项目名称.目录名称''
在项目目录执行命令：'scrapy crawlall'

208、scrapy 中如何实现的记录爬虫的深度？

'DepthMiddleware'是一个用于追踪每个 Request 在被爬取的网站的深度的中间件。
其可以用来限制爬取深度的最大深度或类似的事情。
'DepthMiddleware'可以通过下列设置进行配置(更多内容请参考设置文档):

'DEPTH_LIMIT':爬取所允许的最大深度，如果为 0，则没有限制。
'DEPTH_STATS':是否收集爬取状态。
'DEPTH_PRIORITY':是否根据其深度对 requet 安排优先

209、scrapy 中的 pipelines 工作原理？

Scrapy 提供了 pipeline 模块来执行保存数据的操作。
在创建的 Scrapy 项目中自动创建了一个 pipeline.py 文件，同时创建了一个默认的 Pipeline 类。
我们可以根据需要自定义 Pipeline 类，然后在 settings.py 文件中进行配置即可

210、scrapy 的 pipelines 如何丢弃一个 item 对象？

通过 raise DropItem()方法

211、简述 scrapy 中爬虫中间件和下载中间件的作用？

http://www.cnblogs.com/wupeiqi/articles/6229292.html

212、scrapy-redis 组件的作用？

实现了分布式爬虫，url 去重、调度器、数据持久化
'scheduler'调度器
'dupefilter'URL 去重规则（被调度器使用）
'pipeline'数据持久化

213、scrapy-redis 组件中如何实现的任务的去重？

a. 内部进行配置，连接 Redis
b.去重规则通过 redis 的集合完成，集合的 Key 为：
    key = defaults.DUPEFILTER_KEY % {'timestamp': int(time.time())}
    默认配置：
        DUPEFILTER_KEY = 'dupefilter:%(timestamp)s'
c.去重规则中将 url 转换成唯一标示，然后在 redis 中检查是否已经在集合中存在
    from scrapy.utils import request
    from scrapy.http import Request
    req = Request(url='http://www.cnblogs.com/wupeiqi.html')
    result = request.request_fingerprint(req)
    print(result) # 8ea4fd67887449313ccc12e5b6b92510cc53675c
scrapy 和 scrapy-redis 的去重规则（源码）
1. scrapy 中去重规则是如何实现？

```
class RFPDupeFilter(BaseDupeFilter):
    """Request Fingerprint duplicates filter"""

    def __init__(self, path=None, debug=False):
        self.fingerprints = set()



    @classmethod
    def from_settings(cls, settings):
        debug = settings.getbool('DUPEFILTER_DEBUG')
        return cls(job_dir(settings), debug)

    def request_seen(self, request):
        # 将 request 对象转换成唯一标识。
```

```
        fp = self.request_fingerprint(request)
        # 判断在集合中是否存在，如果存在则返回 True，表示已经访问过。
        if fp in self.fingerprints:
            return True
        # 之前未访问过，将 url 添加到访问记录中。
        self.fingerprints.add(fp)

    def request_fingerprint(self, request):
        return request_fingerprint(request)
```

2. scrapy-redis 中去重规则是如何实现？

```
class RFPDupeFilter(BaseDupeFilter):
    """Redis-based request duplicates filter.

    This class can also be used with default Scrapy's scheduler.

    """

    logger = logger

    def __init__(self, server, key, debug=False):

        # self.server = redis 连接
        self.server = server
        # self.key = dupefilter:123912873234
        self.key = key


    @classmethod
    def from_settings(cls, settings):

        # 读取配置，连接 redis
        server = get_redis_from_settings(settings)
```

```
        #  key = dupefilter:123912873234
        key = defaults.DUPEFILTER_KEY % {'timestamp': int(time.time())}
        debug = settings.getbool('DUPEFILTER_DEBUG')
        return cls(server, key=key, debug=debug)

    @classmethod
    def from_crawler(cls, crawler):

        return cls.from_settings(crawler.settings)

    def request_seen(self, request):

        fp = self.request_fingerprint(request)
        # This returns the number of values added, zero if already exists.
        # self.server=redis 连接
        # 添加到 redis 集合中：1，添加工程；0，已经存在
        added = self.server.sadd(self.key, fp)
        return added == 0

    def request_fingerprint(self, request):

        return request_fingerprint(request)

    def close(self, reason=''):

        self.clear()

    def clear(self):
        """Clears fingerprints data."""
        self.server.delete(self.key)
```

230、scrapy-redis 的调度器如何实现任务的深度优先和广度优先？

https://www.cnblogs.com/pupilheart/articles/9851936.html
https://www.cnblogs.com/pupilheart/articles/9851964.html